ГРНТИ 28.23.37, 28.23.19
ASJC 1702, 1710
OECD 1020

Двухпоточный гибридный метод классификации научно-технических текстов на основе предобученной языковой модели и эмбеддингов графа знаний

А. В. Луценко
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
m2304456@edu.misis.ru

С. С. Мишуров
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
mishurov.s@misis.ru

Аннотация — Работа посвящена автоматической многоклассовой классификации научно-технических текстов, направленной на повышение точности обработки сложной терминологии при сохранении вычислительной эффективности. Для решения поставленной задачи разработан двухпоточный гибридный метод, в котором текстовый поток на базе модели RuBERT и графовый поток с предварительно вычисленными эмбеддингами узлов знаний объединяются на уровне слияния признаков. Эффективность предложенного подхода оценивается путем экспериментального сравнения с базовыми моделями по метрикам F1-score, Accuracy и времени инференса.

Ключевые слова — Классификация научно-технических текстов, трансформерные модели, графы знаний, слияние признаков, обработка естественного языка, векторные представления.

I. ВВЕДЕНИЕ

Архитектура трансформеров стала основой современных методов обработки естественного языка: предобученные модели BERT [1], SciBERT [2] и их русскоязычные аналоги, в частности RuBERT [3], показывают высокое качество в задачах классификации текстов. Вместе с тем научно-технические тексты (НТТ) обладают рядом особенностей: узкоспециализированной терминологией, редкими сущностями, омонимией и сложными концептуальными связями, которые слабо отражаются в статистике совместной встречаемости слов. Трансформер опирается на эти статистические закономерности и не имеет явного доступа к структурированным знаниям предметной области, например к тому, что один метод является разновидностью другого или применяется для определённой задачи.

Естественным решением служит интеграция графов знаний. Однако существующие архитектуры, встраивающие знания непосредственно в механизм внимания, плохо подходят для длинных документов: они увеличивают длину входной последовательности и вычислительные затраты, а ошибки связывания сущностей напрямую искажают представление текста. Альтернативой является разделение обработки на два независимых потока с объединением уже готовых векторных представлений.

Цель работы — разработка гибридного метода классификации НТТ, объединяющего контекстные эмбеддинги RuBERT с предвычисленными эмбеддингами узлов графа знаний. **Гипотеза**: слияние указанных признаков на уровне латентных представлений статистически значимо повышает Macro F1 по сравнению с изолированной моделью RuBERT, при этом время инференса остаётся ниже, чем у методов с глубокой интеграцией графа.

Дальнейшее изложение организовано следующим образом. В разделе II рассмотрены существующие подходы, в разделе III описана математическая модель метода, в разделе IV — протокол экспериментальной оценки, в разделе V — результаты.

II. ОБЗОР СУЩЕСТВУЮЩИХ ПОДХОДОВ

A. Специализированные языковые модели

Применение моделей, обученных на текстах общего назначения, к научным текстам сопряжено со сдвигом предметной области (domain shift). Для его уменьшения была предложена модель SciBERT [2], предобученная на корпусе из 1,14 млн полных текстов научных статей со специализированным словарём SciVocab, что позволило в среднем на 2–3% повысить F1 в ряде научных задач по сравнению с BERT. Для русского языка аналогичную роль играет RuBERT [3], превосходящий мультиязычные модели на русскоязычных задачах, что обосновывает его выбор в качестве текстового энкодера. Тем не менее любая из этих моделей остаётся статистической и не использует явные онтологические связи между

концептами.

B. Интеграция графов знаний в трансформеры

В K-BERT [4] тройки «субъект–отношение–объект» из графа знаний добавляются к предложению, превращая последовательность в дерево; для ограничения «шума знаний» используются мягкие позиционные эмбеддинги и матрица видимости в слое самовнимания. Метод не требует предобучения с нуля, но увеличивает длину последовательности, усиливает квадратичный рост затрат и чувствителен к ошибкам связывания сущностей, что критично для длинных НТТ.

Модель ERNIE [5] интегрирует знания на этапе предобучения: токены выравниваются с эмбеддингами сущностей, а информация об упоминаниях сущностей вводится в представления токенов. Подход использует сущности как независимые векторы и не учитывает структуру графа явно, а также наследует ограничение длины входа в 512 токенов.

C. Эмбеддинги графов знаний

Модель TransE [6] трактует отношение как трансляцию в вещественном пространстве, $\mathbf{h} + \mathbf{r} \approx \mathbf{t}$, и обучается с помощью ранжирующей функции потерь с зазором. Её известное ограничение — неадекватное описание отношений типов 1-to-N, N-to-1 и N-to-N. Модель RotatE [7] моделирует отношения как повороты в комплексном пространстве, $\mathbf{t} = \mathbf{h} \circ \mathbf{r}$, $|r_i| = 1$, что позволяет выражать симметричность, антисимметричность, инверсию и композицию. Алгоритм node2vec [8] строит представления узлов по управляемым случайным блужданиям с параметрами p и q и последующим применением Skip-gram, не требуя явных типов отношений.

D. Слияние признаков

В таксономии мультимодального обучения [9] выделяют раннее слияние, позднее слияние и слияние на уровне признаков. Последнее позволяет сохранить предобученные пространства признаков каждой модальности и обучить классификатор нелинейным взаимодействиям между ними. Эмпирическое подтверждение дала работа [10]: добавление к представлению документа эмбеддингов сущностей Wikidata (TransE, ComplEx) улучшает классификацию по сравнению с BERT без модификации внутренних механизмов трансформера. Наш метод развивает эту идею для русскоязычных НТТ и предметно-ориентированного графа знаний.

III. МАТЕМАТИЧЕСКАЯ МОДЕЛЬ МЕТОДА

A. Постановка задачи и архитектура

Требуется построить отображение $f : D \to Y$, где D — множество документов, $Y = \{y_1, \dots, y_C\}$ — множество классов (рубрик). Метод состоит из двух потоков и классификатора. Эмбеддинги узлов графа вычисляются заранее (офлайн), поэтому при классификации динамический обход графа не выполняется.

B. Текстовый поток

Документ токенизируется словарём RuBERT; к последовательности добавляются служебные токены: $X = [x_{\text{CLS}}, x_1, \dots, x_n, x_{\text{SEP}}]$, $n + 2 \le 512$. Модель формирует матрицу скрытых состояний

$$H = \text{RuBERT}(X) \in \mathbb{R}^{(n+2)\times d_{\text{text}}}, \tag{1}$$

$d_{\text{text}} = 768$, а вектор документа берётся из позиции токена [CLS]:

$$V_{\text{text}} = H[0] \in \mathbb{R}^{768}. \tag{2}$$

Параллельно NER-модуль выделяет множество научно-технических концептов $E = \{e_1, \dots, e_k\}$.

C. Графовый поток

Граф знаний — направленный мультиграф $G = (V_{kg}, R)$. Функция вложения $\Phi : V_{kg} \to \mathbb{R}^{d_{kg}}$ обучается заранее на всём графе (TransE, RotatE или node2vec) и далее фиксируется. Каждая сущность $e_i \in E$ связывается с узлом $v_i \in V_{kg}$ (entity linking); несвязанные сущности отбрасываются. Графовое представление документа получается усреднением:

$$V_{\text{graph}} = \frac{1}{|E_{\text{linked}}|} \sum_{e_i \in E_{\text{linked}}} \Phi(v_i), \tag{3}$$

а при $E_{\text{linked}} = \varnothing$ принимается $V_{\text{graph}} = \mathbf{0} \in \mathbb{R}^{d_{kg}}$, и классификация опирается только на текстовый поток. Усреднение не зависит от порядка упоминаний, а поиск вектора в таблице имеет сложность $O(1)$ на сущность.

D. Слияние и классификация

Векторы объединяются конкатенацией:

$$V_{\text{final}} = [V_{\text{text}} \oplus V_{\text{graph}}] \in \mathbb{R}^{d_{\text{text}}+d_{kg}}. \tag{4}$$

Классификатор — перцептрон с одним скрытым слоем:

$$h = \text{ReLU}(W_1 V_{\text{final}} + b_1), \tag{5}$$

$$\hat{y} = \text{Softmax}\big(W_2\, \text{Dropout}(h, p) + b_2\big), \tag{6}$$

где $W_1 \in \mathbb{R}^{d_{\text{hidden}}\times(d_{\text{text}}+d_{kg})}$, $W_2 \in \mathbb{R}^{C\times d_{\text{hidden}}}$, $p \in [0{,}3;\ 0{,}5]$. Обучение минимизирует перекрёстную энтропию

$$\mathcal{L} = -\sum_{c=1}^{C} y_c \log \hat{y}_c \tag{7}$$

оптимизатором AdamW; параметры W_1, b_1, W_2, b_2 и, опционально, верхние слои RuBERT дообучаются, а таблица Ф остаётся замороженной.

E. Вычислительные свойства

Графовый поток добавляет к стоимости инференса $O(k)$ операций поиска и $O(k\, d_{kg})$ операций усреднения, не зависящих от размера графа и не требующих его обхода. Следует отметить, что стоимость самого трансформера $O(n^2)$ остаётся и входит в оба сравниваемых варианта; выигрыш относится к отсутствию дополнительных затрат на инжекцию троек и динамическую агрегацию соседей. Кроме того,

Таблица I. Сравнение методов на тестовой выборке

Метод	Macro F1	Micro F1	Acc.	мс/док
TF-IDF + LR	–	–	–	–
RuBERT (text-only)	–	–	–	–
K-BERT / ERNIE	–	–	–	–
Предложенный (TransE)	–	–	–	–
Предложенный (RotatE)	–	–	–	–
Предложенный (node2vec)	–	–	–	–

сущности для графового потока могут извлекаться из всего документа, тогда как текстовый поток ограничен окном в 512 токенов.

IV. ПРОТОКОЛ ЭКСПЕРИМЕНТАЛЬНОЙ ОЦЕНКИ

A. Данные и граф знаний

[ЗАПОЛНИТЬ: названия датасетов русскоязычных НТТ, число документов и классов, разбиение train/val/test; источник и размер предметно-ориентированного графа знаний (число узлов, отношений); NER-модель и метод entity linking; доля документов, для которых найдена хотя бы одна сущность.]

B. Метрики

Так как рубрики научных публикаций распределены несбалансированно, основной метрикой выбрана Macro F1 (чувствительна к редким направлениям); дополнительно применяются Micro F1 и Accuracy. Эффективность оценивается средним временем инференса на документ (мс/док).

C. Базовые модели

Сравнение проводится с (1) TF-IDF с логистической регрессией или SVM; (2) изолированной моделью RuBERT (только вектор [CLS]); (3) опционально — с методами глубокой интеграции графа типа K-BERT и ERNIE. Метод считается успешным, если Macro F1 превышает значение для изолированного RuBERT при времени инференса не выше, чем у методов глубокой интеграции. Кроме того, сравниваются варианты эмбеддингов графа (TransE, RotatE, node2vec) и значимость различий [ЗАПОЛНИТЬ: статистический тест, число запусков с разными seed].

V. РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ

Результаты экспериментов приведены в табл. I.

[ЗАПОЛНИТЬ: обсуждение результатов: вклад графа знаний относительно RuBERT, сравнение алгоритмов эмбеддингов, анализ ошибок для редких классов, влияние качества entity linking, время инференса.]

VI. ЗАКЛЮЧЕНИЕ

Предложен и формализован гибридный метод классификации научно-технических текстов, объединяющий контекстные эмбеддинги RuBERT и предвычисленные эмбеддинги узлов графа знаний на уровне признаков. Метод не модифицирует внутренние механизмы трансформера и не требует графовых нейронных сетей при инференсе. [ЗАПОЛНИТЬ: основные количественные выводы.] Дальнейшие исследования предполагают сравнение TransE, RotatE и node2vec, взвешенное (например, на основе внимания) агрегирование эмбеддингов сущностей вместо простого усреднения и анализ устойчивости к ошибкам связывания сущностей.

СПИСОК ЛИТЕРАТУРЫ

[1] Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proc. NAACL-HLT. 2019. P. 4171–4186.

[2] Beltagy I., Lo K., Cohan A. SciBERT: A Pretrained Language Model for Scientific Text // Proc. EMNLP-IJCNLP. Hong Kong: ACL, 2019. P. 3615–3620. DOI: 10.18653/v1/D19-1371.

[3] Куратов Ю. М., Архипов М. Я. Адаптация языковой модели BERT для русского языка и оценка ее качества // Компьютерная лингвистика и интеллектуальные технологии: по материалам конф. «Диалог». 2019. Вып. 18 (25). С. 546–556.

[4] Liu W., Zhou P., Zhao Z. et al. K-BERT: Enabling Language Representation with Knowledge Graph // Proc. AAAI Conf. on Artificial Intelligence. 2020. Vol. 34, No. 3. P. 2901–2908. DOI: 10.1609/aaai.v34i03.5681.

[5] Zhang Z., Han X., Liu Z., Jiang X., Sun M., Liu Q. ERNIE: Enhanced Language Representation with Informative Entities // Proc. ACL. 2019. P. 1441–1451.

[6] Bordes A., Usunier N., Garcia-Duran A. et al. Translating Embeddings for Modeling Multi-relational Data // Advances in Neural Information Processing Systems. 2013. Vol. 26. P. 2787–2795.

[7] Sun Z., Deng Z.-H., Nie J.-Y., Tang J. RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space // Proc. ICLR. 2019. URL: https://arxiv.org/abs/1902.10197.

[8] Grover A., Leskovec J. node2vec: Scalable Feature Learning for Networks // Proc. 22nd ACM SIGKDD. New York: ACM, 2016. P. 855–864. DOI: 10.1145/2939672.2939754.

[9] Baltrušaitis T., Ahuja C., Morency L.-P. Multimodal Machine Learning: A Survey and Taxonomy // IEEE Trans. Pattern Anal. Mach. Intell. 2019. Vol. 41, No. 2. P. 423–443. DOI: 10.1109/TPAMI.2018.2798607.

[10] Ostendorff M., Bourgonje P., Berger M., Moreno-Schneider J., Rehm G., Gipp B. Enriching BERT with Knowledge Graph Embeddings for Document Classification // arXiv:1909.08402. 2019.